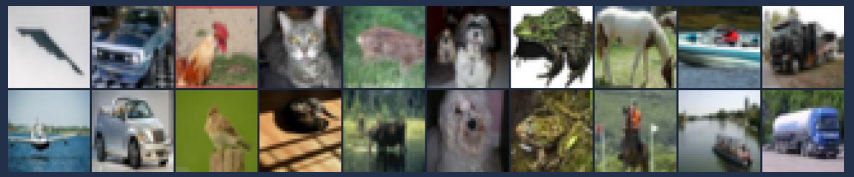
UYGULAMALI YAPAY ZEKA · DÖNEM PROJESİ · FAZ 1

Fashion-MNIST ve CIFAR-10 Üzerinde Görüntü Sınıflandırma

Hüseyin Mehmet Şencan · 241230040 · Ders sorumlusu: Dr. Öğr. Üyesi Hayri İncekara



Fashion-MNIST · 28×28 grayscale

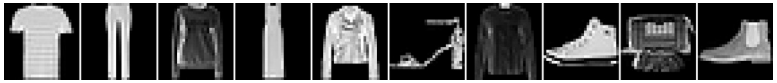


CIFAR-10 · 32×32 RGB

github.com/shencan03/uyz-odev

Problem ve Amaç

Aynı görev, iki zorluk düzeyi: sade ürün görüntüleri ve karmaşık doğal sahneler



Fashion-MNIST

Logistic Regression vs MLP

Soru: Doğrusal olmayan tek bir gizli katman ne kadar kazandırır?

Zorluk: Shirt, T-shirt, Pullover ve Coat birbirine çok benzer



CIFAR-10

SmallCNN (2 evrişim bloğu)

Soru: 0,5M parametreli küçük CNN, 36M parametreli mimarilere ne kadar yaklaşır?

Zorluk: Arka plan çeşitliliği; cat/dog, automobile/truck

Ortak değerlendirme: doğruluk · makro-F1 · karışıklık matrisi · eğitim süresi

Veri Setleri

Fashion-MNIST

70.000

görüntü · 10 sınıf · tamamı etiketli

- 28×28 · grayscale (1 kanal)
- 60.000 eğitim / 10.000 test
- Sınıf başına 6.000 / 1.000 → tam dengeli
- Zalando Research, 2017

github.com/zalandoresearch/fashion-mnist

CIFAR-10

60.000

görüntü · 10 sınıf · tamamı etiketli

- 32×32 · RGB (3 kanal)
- 50.000 eğitim / 10.000 test
- Sınıf başına 5.000 / 1.000 → tam dengeli
- Krizhevsky, Toronto Üni., 2009

cs.toronto.edu/~kriz/cifar.html

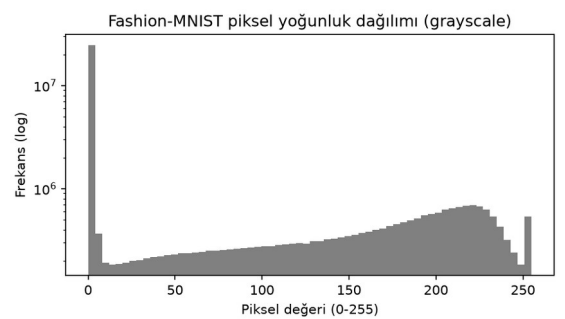
Veri Analizi

0 eksik veya geçersiz etiket

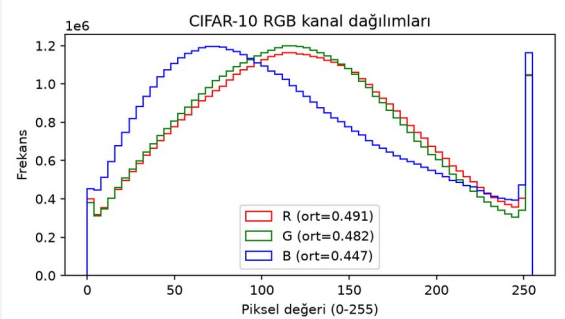
0 birebir yinelenen görüntü

0 eğitim–test kesişimi

MD5 hash ile kontrol edildi. Not: CIFAR-10 test görüntülerinin %3,3'ünün eğitimde yakın kopyası olduğu raporlanmıştır (Barz ve Denzler, 2020).



Piksellerin %50'si siyah arka plan



Mavi kanal ortalaması düşük (0,447)



CIFAR-10 sınıf ortalamaları bulanık, arka plan baskın (airplane/ship mavi) → konumdan bağımsız özellik öğrenen CNN gerekli

Ön İşleme

1 Ölçekleme

uint8 [0, 255] → float32 [0, 1]

2 Kanal düzeni

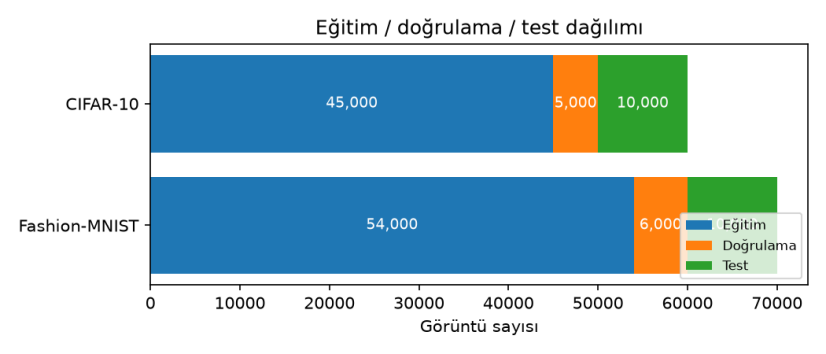
(N, H, W, C) → (N, C, H, W) PyTorch formatı

3 Stratified bölme

Eğitimin %10'u doğrulama, sınıf başına eşit, seed = 42

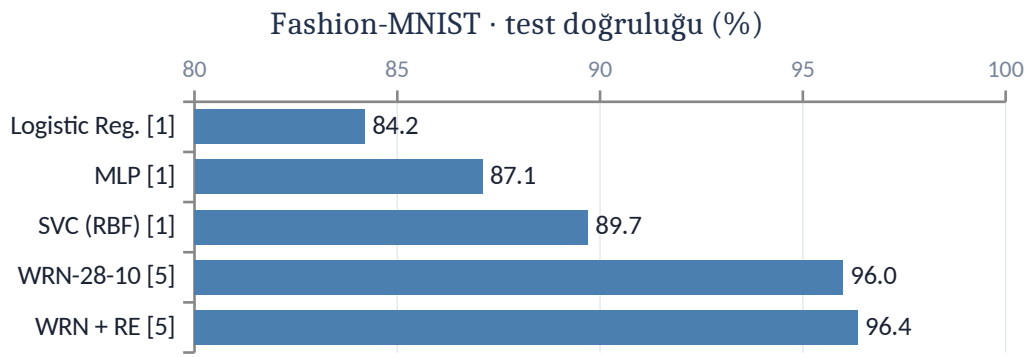
4 Standardizasyon

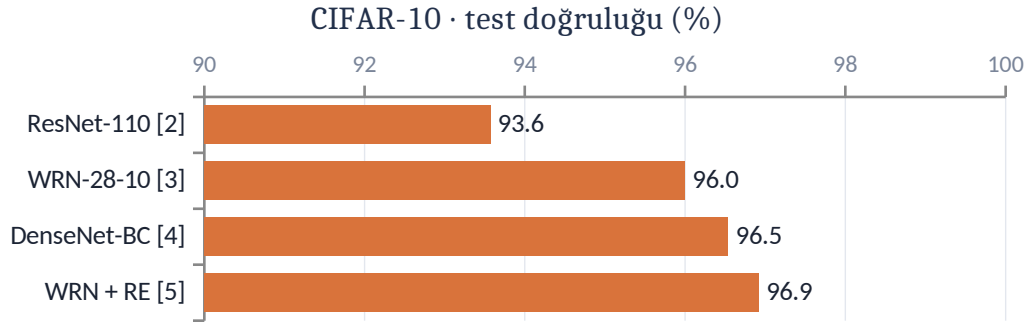
μ ve σ yalnızca eğitim alt kümesinden → sızıntı yok



Özellik	Önce	Sonra
Bölmeler	60k / 10k 50k / 10k	54k / 6k / 10k 45k / 5k / 10k
Format	uint8 [0, 255]	float32, standardize
Eğitim ort. / std	ham değerler	0,00 / 1,00
Eksik veri	Yok	Yok

Literatür Taraması





Sığ modeller

LR %84,2 → MLP %87,1 → SVM %89,7: doğrusal olmayanlık kazandırıyor

Derin CNN'ler

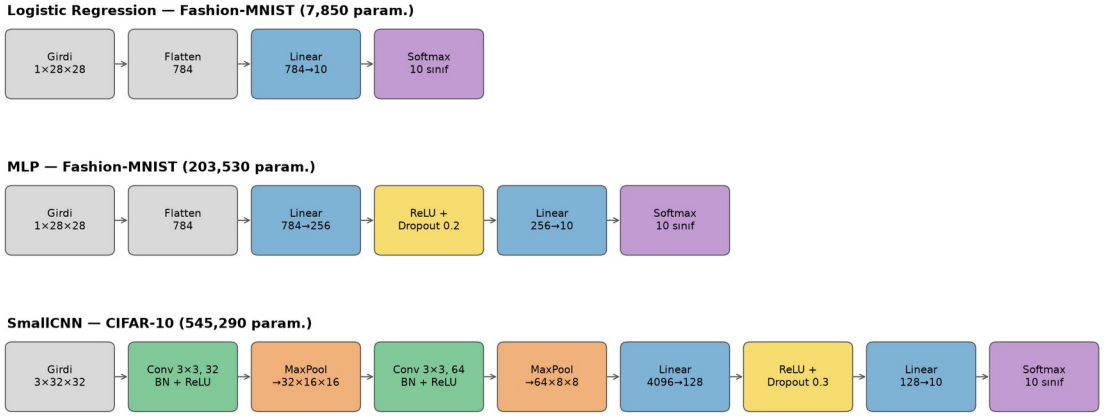
%93,6–96,9; ama 1,7M–36,5M parametre ve veri artırma gerekiyor

Boşluk

Hepsi yalnızca doğruluk raporluyor; sınıf bazlı hata analizi yok

[1] Xiao 2017 · [2] He 2016 · [3] Zagoruyko 2016
[4] Huang 2017 · [5] Zhong 2020 · RE: Random Erasing

Seçilen Yöntem ve Mimariler



Değerlendirme

- Doğruluk
- Makro-F1
- Karışıklık matrisi
- Eğitim süresi (M4 · MPS)

Logistic Regression

Bilinçli "uygun olmayan" doğrusal baseline · 7,9K param. · lit. %84,2

MLP (256, ReLU)

Tek fark gizli katman → doğrusal olmayanlığın katkısı · 204K param. · lit. %87,1

SmallCNN

Evrişim + pooling ile yerel özellik · 545K param. · M4'te dakikalar

Faz 1 Tamamlandı · Faz 2 Planı

- ✓ Veri setleri bulundu ve indirildi
- ✓ Analiz ve görselleştirme
- ✓ Ön işleme hattı (sızıntısız)
- ✓ Literatür taraması: 5 çalışma
- ✓ Mimariler tanımlandı ve test edildi

Faz 2

1. Eğitim döngüsü + erken durdurma
2. Hiperparametre seçimi (doğrulama seti)
3. Test: doğruluk, makro-F1, süre
4. Karışıklık matrisi ile hata analizi
5. Literatürle karşılaştırma ve makale

Kod ve rapor: github.com/shencan03/uyz-odev · Teşekkürler, sorularınızı alabilirim.